IIC 2433 Minería de Datos

https://github.com/marcelomendoza/IIC2433

- TSNE y UMAP -

Stochastic Neighbor Embedding (SNE)

Objetivo: Proyectar los datos a 2D o 3D para visualización.

Idea: Convertir distancias (Euclideanas) a probabilidades condicionales.

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_i - x_k\|^2 / 2\sigma_i^2\right)}$$

Vecindario (parametrizable)

Definimos la proyección tal que: $$q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)}$$

Notar que: $p_{i|i}$ = $q_{i|i} = 0.$

Stochastic Neighbor Embedding (SNE)

Visualización que preserva
distancias del espacio original

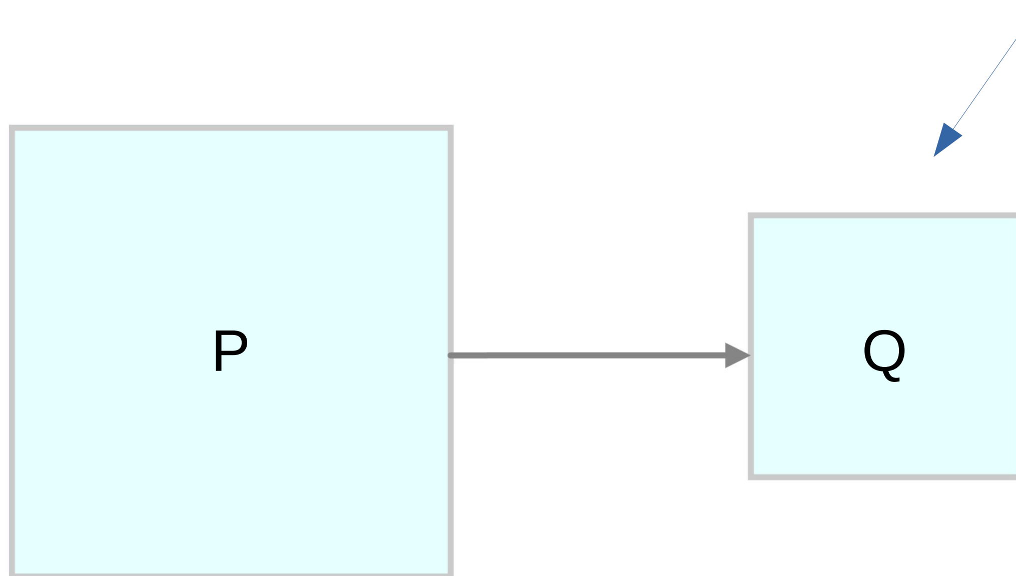

D-dimensional

Bidimensional

Stochastic Neighbor Embedding (SNE)

Hacemos lo mismo en un espacio de menor dimensionalidad (proyección):

distancia

probabilidad

$$q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)}$$

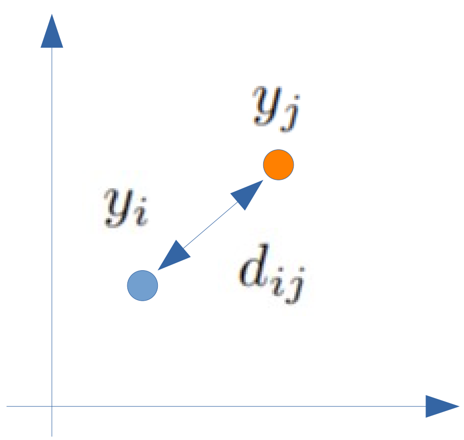

probabilidad

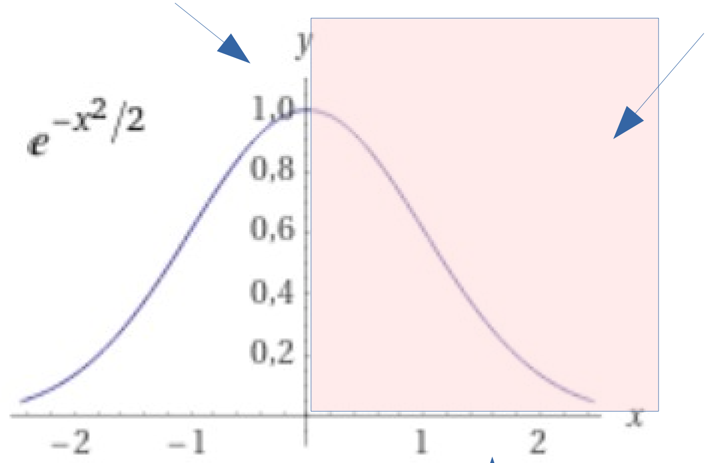

distancia

Stochastic Neighbor Embedding (SNE)

¿Cómo mido cuanto se parece el espacio original al proyectado?

Voy a comparar las distribuciones de probabilidad P y Q.

<u>Divergencia de Kullback-Leibler</u>:

$$C = \sum_i KL(P_i||Q_i) = \sum_i \sum_j p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$$

La divergencia es menor en la medida que ambas distribuciones son más parecidas.

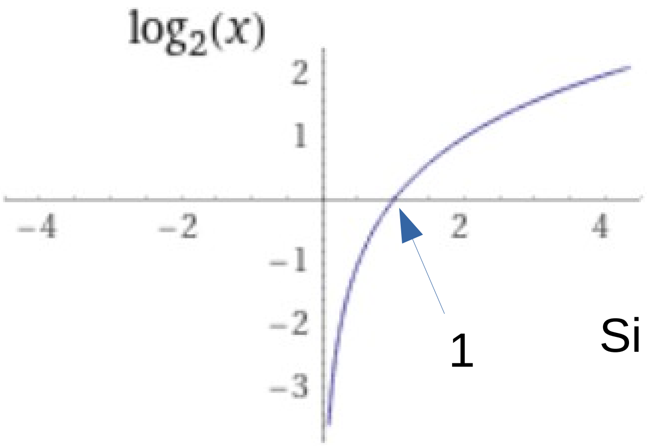

Si p~q → log p/q ~ 0

Model complexity

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

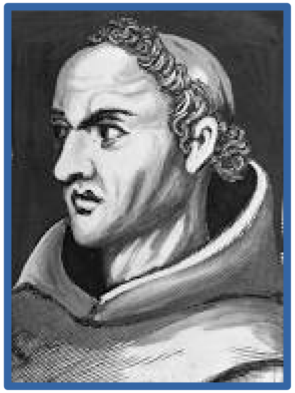

Model complexity

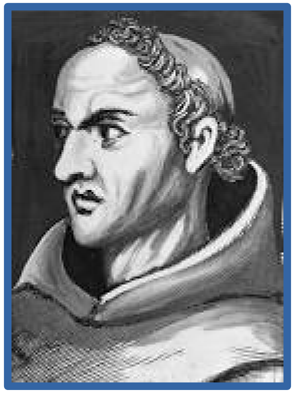

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Model complexity

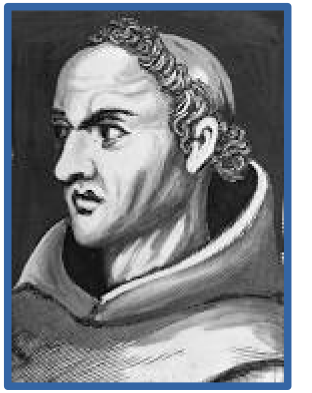

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Explicación: entropía como medida de información.

Lanzamos una moneda 4 veces. Posibles estados del ejercicio: $2 \cdot 2 \cdot 2 \cdot 2$

estados

$\log_2(16) = 4$ ← Bits para codificar los estados

ej. CSSC

Model complexity

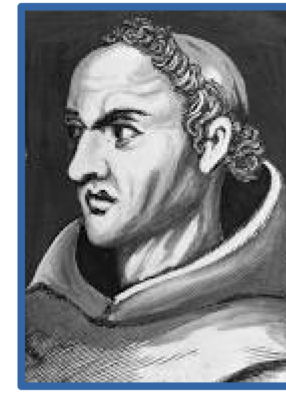

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Explicación: entropía como medida de información.

Lanzamos una moneda 4 veces. Posibles estados del ejercicio: $2 \cdot 2 \cdot 2 \cdot 2$

estados

$\log_2(16) = 4$ Bits para codificar los estados

ej. CSSC

Probabilidad de un resultado en particular:

p=1/estados $\longrightarrow$ $-\log_2(1/16) = 4$

Model complexity

Si los eventos no son equiprobables, debemos promediar:

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Información codificada en el espacio original

Volvamos a SNE:

Me da el # de estados promedio (vecinos de cada punto)

El usuario define: $Perp(P_i) = \boxed{2^{H(P_i)}}$

lo cual permite determinar σ_i (internamente).

Es decir, el usuario define la complejidad de la proyección, la cual es modelada en sigma!!!

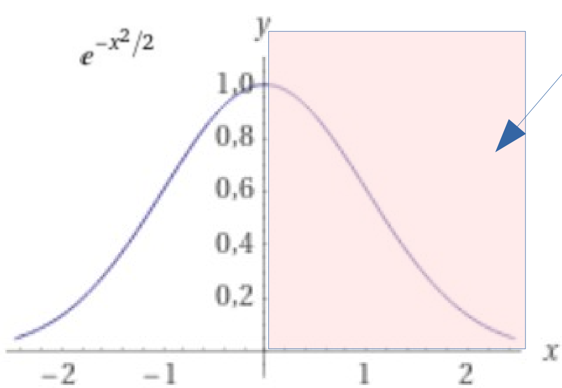

Menos pares

$\sigma = 1$

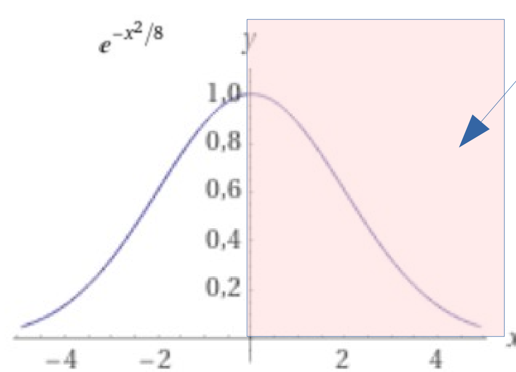

Más pares

$\sigma = 2$

Stochastic Neighbor Embedding (SNE)

- Debemos calibrar el parámetro perplexity.

- El parámetro nos indica la complejidad de la proyección:

  mayor perplejidad → menor parsimonia

- Mayor perplejidad → mayor p → más vecinos → mayor sigma

Nota: En rigor usaremos una versión simétrica de SNE denominada t-SNE (reemplaza KL por Jensen-Shannon).

Uniform Manifold Approximation and Projection (UMAP)

Idea básica: UMAP calcula un grafo que representa los datos, luego aprende un embedding a partir del grafo.

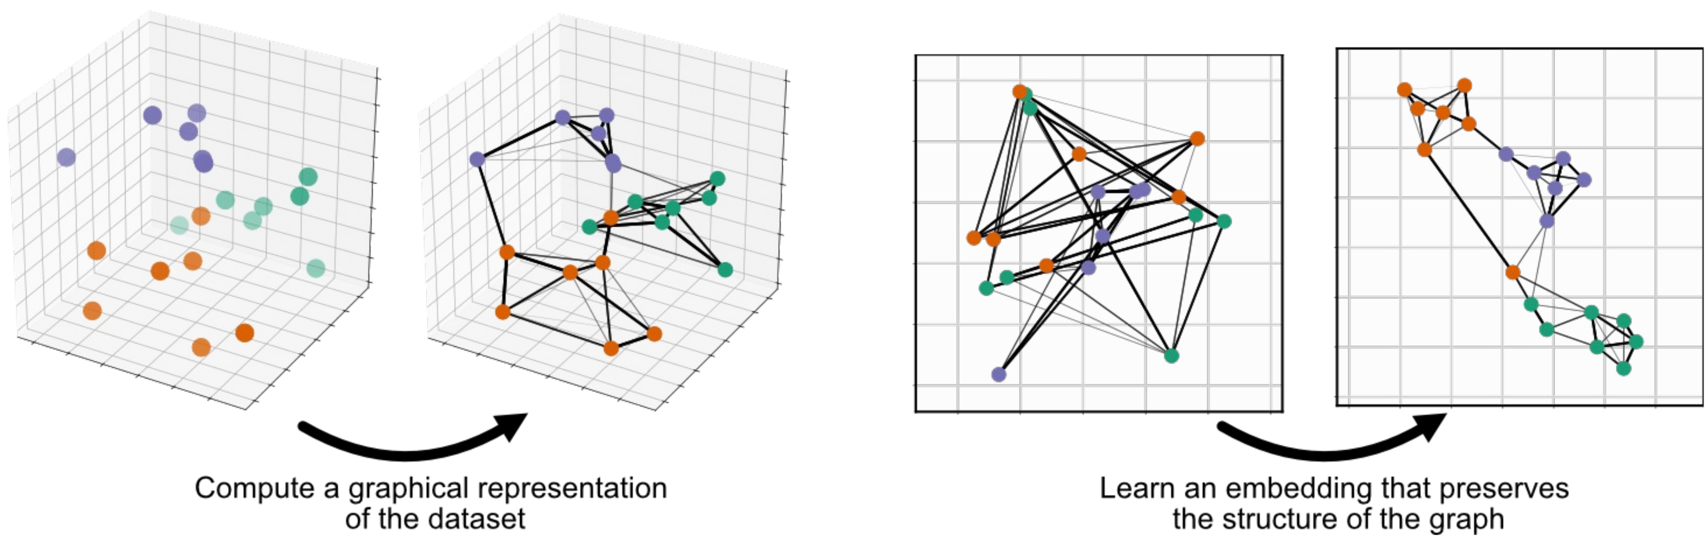

Uniform Manifold Approximation and Projection (UMAP)

UMAP paramétrico